Python 编程与深度学习

实验三&实验四

医疗影像异常分类与腮腺肿瘤 MRI 分割

班级：自动化 2303

学号：20237563

姓名：谢怡诺

实验框架：PyTorch

报告日期：2026 年 10 月 18 日

报告依据实际数据审计、训练日志与模型预测编写。正文以数据集划分、模型架构、训练方案及结果分析替代完整代码；源代码与可复现命令随项目提交。

1 实验概况与运行环境

1.1 实验目标

实验三使用课程提供的 MURA 影像，以 PyTorch 实现正常 / 异常二分类，搭建基础 CNN，并与从头训练和迁移学习的 ResNet18 比较。实验四使用公开腮腺 MRI 与肿瘤掩膜，比较基础编码器—解码器和 U-Net，以 Dice 衡量分割效果。

MURA 的原始标签表示正常或异常，并不是骨折确诊标签。因此，本实验对课件中的“骨折影像分类”按所给数据的真实标签实现，结果仅解释为肌肉骨骼影像异常识别。异常可能来自多类病变或术后改变，不能把本报告的敏感度称为骨折诊断敏感度。

项目	实际配置
操作系统	Windows-10-10.0.19045-SP0
Python	3.13.15
深度学习框架	PyTorch 2.9.1+cu128 / torchvision 0.24.1+cu128
计算设备	NVIDIA GeForce RTX 3050 Ti Laptop GPU
显存	4 GB；混合精度训练
依赖管理	uv + pyproject.toml + uv.lock
随机种子	42、43、44；数据划分固定为种子 42

1.2 比较协议与报告结构

全部模型先按内部验证指标选取最佳轮次，再对保留评估集计算一次结果。三个训练随机种子共享同一数据划分；表中“均值±标准差”描述初始化与训练随机性的变化，不等于跨医院泛化误差。另以种子 42 作为预先指定的展示运行，展示曲线、预测样例及按患者 / 病例组重采样的置信区间。

项目保留每轮损失、模型配置、最佳权重、逐样本概率、划分清单及数据排除原因。报告第 2—6 节为分类实验，第 7—10 节为分割实验，第 11 节汇总复现方法与限制。

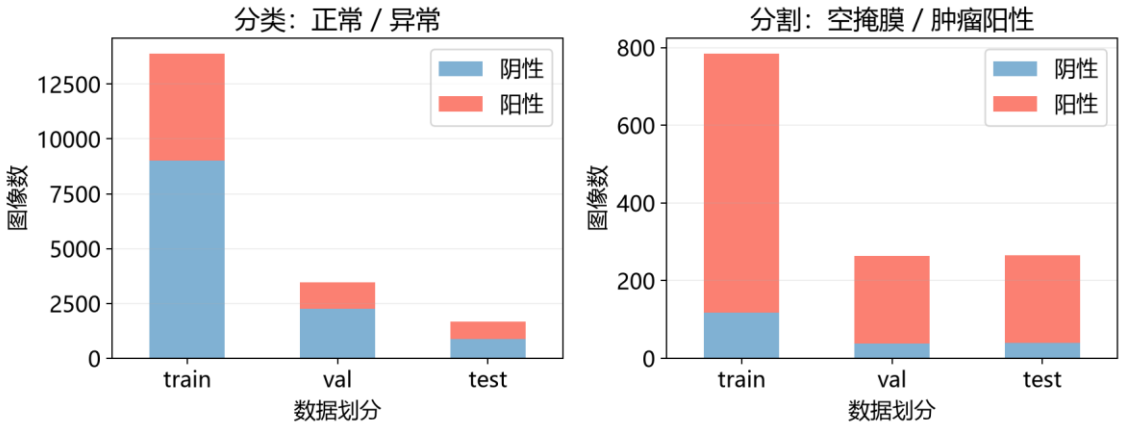


图 1 两项任务的最终图像数量与正负标签分布。

2 实验三：数据集与划分方案

2.1 数据来源与标签

课程数据由 train_XR_ELBOW、train_XR_FINGER、train_XR_FOREARM、train_XR_HAND 与 valid 五个压缩包组成，覆盖肘、手指、前臂和手四类上肢部位。目录中的 study*_positive 映射为 1（异常），study*_negative 映射为 0（正常），检查标签用于该检查下的多张视图。未使用完整 MURA 中的肩、腕与肱骨数据。[1]

从压缩包完整读取 19,067 张图片，未发现不可解码文件。发现 1 张开发集图片与另一集合图片内容完全相同，保留评估侧并排除开发侧副本，最终使用 19,066 张。相同集合内仍有 4 张哈希重复图片，未跨集合，不造成评估泄漏，但可能轻微改变样本权重。

集合	图像数	患者数	检查数	异常图像数
训练	13,904	4744	5267	4893
内部验证	3,477	1188	1317	1222
保留评估	1,685	509	633	816

2.2 防止数据泄漏

原 train 按患者分组，使用 StratifiedGroupKFold 五折中的一折作为约 20%的内部验证集，分层变量为部位与标签。原 valid 完整保留到训练结束后评估，本文称“保留评估集”，并非 MURA 官方隐藏测试集。患者编号同时跨部位分组，使同一患者的不同检查、不同视角不会分别进入训练和验证。审计确认任意两个集合的患者交集与跨集合相同图像哈希均为 0。

2.3 影像预处理

图像转为灰度，保持原宽高比缩放并用黑色边缘填充至 160×160；复制为三通道后采用 ImageNet 均值和标准差归一化。所有分类模型使用相同处理。训练阶段进行水平翻转及±10°仿射变换，平移不超过 5%、缩放 0.9—1.1；内部验证和保留评估阶段不做随机增强。像素缓存仅加速读取，不改变标签或划分。

部位	正常图像	异常图像	合计
XR_ELBOW	3152	2235	5387
XR_FINGER	3343	2214	5557
XR_FOREARM	1313	811	2124
XR_HAND	4327	1671	5998

3 模型架构与优化方法

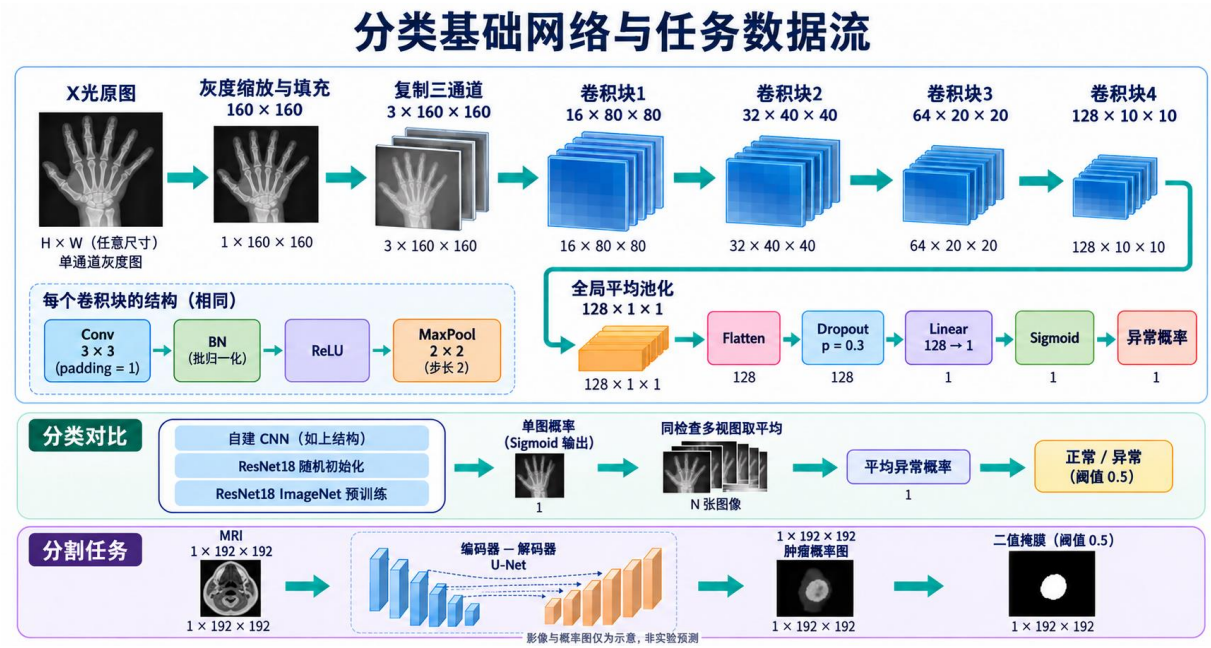


图 2 分类基础网络与分割任务的数据流；尺寸为通道×高×宽。AI 生成示意，影像非实验预测。

模型	结构与初始化	参数量
自建 CNN	4 个卷积块+全局平均池化+ Dropout + 线性分类器	97,809
ResNet18 从头训练	ResNet18；全部参数随机初始化	11,177,025
ResNet18 迁移学习	ResNet18；ImageNet 预训练；替换二分类输出层并全网络微调	11,177,025

基础 CNN 每个块为 3×3 卷积、批归一化、ReLU 和 2×2 最大池化，通道依次为 16、32、64、128。全局平均池化后使用丢弃率 0.3 的 Dropout，输出一个 logit。残差网络通过恒等捷径学习残差映射，有助于更深网络的梯度传播；其原始思想见文献[2]。

$$h(x) = F(x) + x$$

3.1 类别不平衡与损失函数

训练集正常图像多于异常图像。仅根据训练集统计阳性权重 $w=N_0/N_1=1.842$，并在 BCEWithLogitsLoss 中加权异常类别；没有根据评估集重新计算权重。

$$L_BCE = -(1/N)\,\Sigma_i\,[w\,y_i\,log\,\sigma(z_i) + (1-y_i)\,log(1-\sigma(z_i))]$$

3.2 训练与模型选择

三个模型各训练 16 轮，批量 32，使用 AdamW，权重衰减 10^{-4}和余弦学习率调度。从头训练模型初始学习率 10^{-3}，迁移学习为 2×10^{-4}，避免预训练特征被大幅更新。最佳模型按内部验证“检查级 AUROC”选择，预测阈值事先固定为 0.5。每个模型运行种子 42、43、44。迁移学习同时改变初始化和学习率，不作为纯架构消融。原始墙钟计时包含运行暂停或等待，不用于模型速度比较。

4 分类结果：总体性能与不确定性

4.1 三次训练的检查级结果

同一检查的多视图图像概率先取算术平均，再计算检查级指标，以匹配原始标签粒度。AUROC 衡量概率排序能力，准确率与 F1 受固定阈值影响，二者不必同时达到最优。

$$p_study = (1/K)\,\Sigma_k\,\sigma(z_k),\quad \hat{y}_study = 1[p_study \geq 0.5]$$

模型	AUROC	准确率	F1	敏感度
自建 CNN	0.720 ± 0.000	0.676 ± 0.011	0.626 ± 0.018	0.615 ± 0.052
ResNet18 从头训练	0.761 ± 0.007	0.689 ± 0.005	0.673 ± 0.002	0.726 ± 0.017
ResNet18 迁移学习	0.862 ± 0.011	0.806 ± 0.008	0.751 ± 0.014	0.667 ± 0.022

本次三次重复中，平均 AUROC 最高的是 ResNet18 迁移学习（0.862），相对基础 CNN 的差值为 +0.142。这说明在本数据划分和训练预算下，该方案具有较好的异常排序能力；不能据此直接推断其在其他机构或所有骨折类型上同样有效。

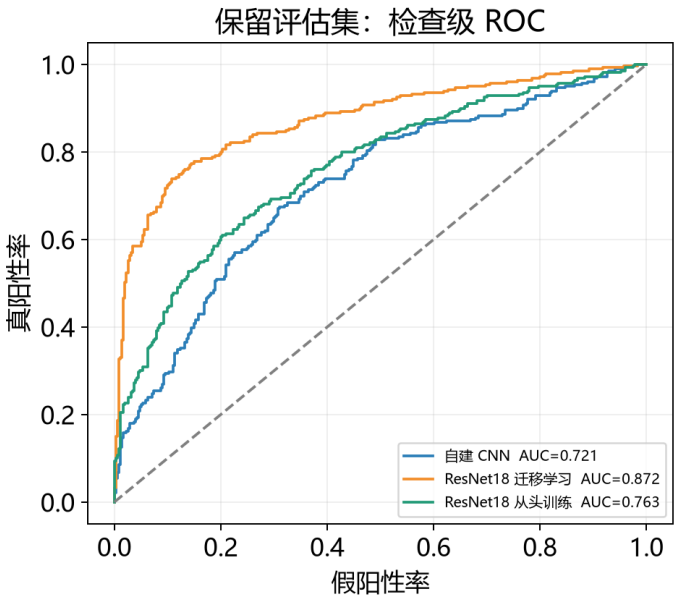


图 3 种子 42 的保留评估集检查级 ROC 曲线。

4.2 结果原因分析

三种模型的平均检查级 AUROC 分别为 0.720、0.761 和 0.862。从头训练 ResNet18 比自建 CNN 高约 0.041，可能与更强的特征表达能力有关。基础 CNN 结构较浅，连续池化和全局平均池化可能限制细小局部异常信息的保留；ResNet18 的多层残差结构有助于学习更复杂的影像特征。但本实验没有直接测量特征质量，不能将这些机制解释视为已证实的原因。

预训练 ResNet18 比从头训练版本高约 0.101。ImageNet 预训练提供的边缘、纹理等初始特征可能帮助模型适应 X 光任务，较小的微调学习率也可能有助于保留已有特征。两方案同时改变了初始化和学习率，因此不能把全部提升单独归因于预训练。

从头训练 ResNet18 的三个种子运行均在第 16 轮，即训练结束时取得最高内部验证 AUROC，提示其可能尚未充分收敛；但最佳轮次处于末轮并不能单独证明收敛不足。当前比较反映固定 16 轮训练预算下的表现，不能据此认定从头训练的最终性能上限更低。

上述机制解释需要补充证据。现已完成探索性补充实验，详见 4.4 节。补充结果单独报告，不并入 4.1 节原有三种子均值；特征表达机制仍未被直接验证。

4.3 患者聚类 Bootstrap

展示运行（种子 42）	AUROC	95%区间
自建 CNN	0.721	[0.679, 0.760]
ResNet18 从头训练	0.763	[0.725, 0.799]
ResNet18 迁移学习	0.872	[0.843, 0.899]

按患者有放回抽样 1,000 次，每次保留被抽中患者的全部检查，再取 2.5%与 97.5%分位数。该区间仅描述固定模型在当前保留患者样本上的抽样不确定性，未包含训练和医院分布变化。区间重叠与否均不能替代正式配对显著性检验。

4.4 补充实验：初始化与训练预算

为进一步检查 4.2 节的解释，固定种子 42，分别训练随机初始化和 ImageNet 预训练 ResNet18，统一初始学习率 0.001、40 轮余弦调度。模型架构、数据划分、增强、批量及损失保持相同，仍仅按内部验证检查级 AUROC 选择最佳模型，阈值固定 0.5。补充实验在查看原保留评估结果后设计，因此属于探索性分析，未获得新的独立测试集。

模型（种子 42）	训练预算	初始 lr	最佳轮次	验证 AUC	保留评估 AUC
ResNet18 从头训练	原方案 16 轮	0.001	16	0.762	0.763
ResNet18 从头训练	补充 40 轮	0.001	40	0.798	0.783
ResNet18 迁移学习	原方案 16 轮	0.0002	10	0.868	0.872
ResNet18 迁移学习	补充 40 轮	0.001	25	0.866	0.852

从头训练 ResNet18 的保留评估 AUROC 由 0.763 提高至 0.783（差值+0.020），支持训练预算会影响本任务表现。其最佳模型仍在第 40 轮，说明当前预算尚不能确定其性能上限；不能据此直接断言已经收敛或仍未收敛。延长训练同时改变余弦调度长度，因此提升不能仅归因于增加轮次。

在相同学习率和 40 轮预算下，预训练版本保留评估 AUROC 为 0.852，比随机初始化高 0.069，为预训练初始化在当前设置下的优势提供补充证据。它在验证集选择的最佳轮次为 25。该结果支持初始化的作用，但不能证明优势具体来自哪类边缘或纹理特征。

预训练补充方案的保留评估 AUROC 低于原种子 42 方案的 0.872，说明统一学习率及增加轮次没有让所有模型都提高。两方案同时改变学习率与调度长度，不能将下降单独解释为学习率过大或训练过久。所有模型仍按验证集选择，未根据保留评估分数重新挑选轮次。

结论范围：上述补充实验仅有一个随机种子，未作配对显著性检验，也未直接测量特征质量。当前证据支持训练配置和初始化对结果有影响，不构成对机制的因果证明。完整配置、逐轮曲线、最佳权重和逐检查预测保存在 artifacts/supplementary/initialization_40epochs_lr001/。

5 分类阈值表现与分部位分析

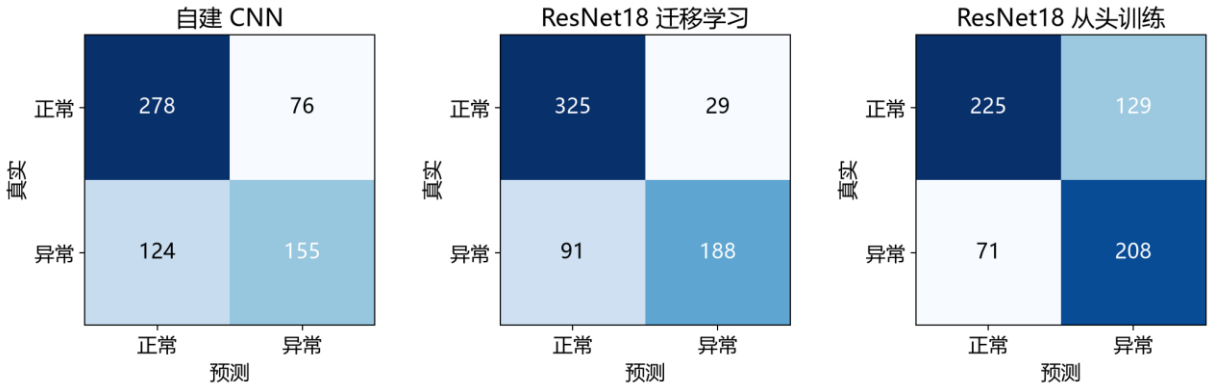


图 4 种子 42、阈值 0.5 的检查级混淆矩阵；行是真实标签，列为预测标签。

模型（种子 42）	敏感度	特异度	Kappa	平衡准确率
自建 CNN	0.556	0.785	0.347	0.670
ResNet18 从头训练	0.746	0.636	0.373	0.691
ResNet18 迁移学习	0.674	0.918	0.606	0.796

$$Sensitivity = TP/(TP + FN),\ \ Specificity = TN/(TN + FP)$$

$$F1 = 2TP/(2TP + FP + FN)$$

敏感度衡量异常检查被检出的比例，特异度衡量正常检查被正确排除的比例。加权损失并不保证阈值 0.5 同时兼顾二者；若未来针对漏检调整阈值，应仅在开发数据上确定，并另设新的独立评估数据。本文未根据保留评估结果回调阈值。

部位	自建 CNN AUC	ResNet 从头 AUC	迁移学习 AUC
XR_ELBOW	0.730	0.772	0.903
XR_FINGER	0.761	0.804	0.862
XR_FOREARM	0.693	0.767	0.921
XR_HAND	0.680	0.715	0.803

训练与保留评估的异常图像比例分别为 35.2%与 48.4%，因此不能直接用训练与评估准确率的差值判断过拟合。部位表为种子 42 的描述性结果；样本较少的亚组不宜过度排名。检查平均可减轻部分单图波动，但也可能稀释局灶异常信号。

6 分类训练曲线与误判分析

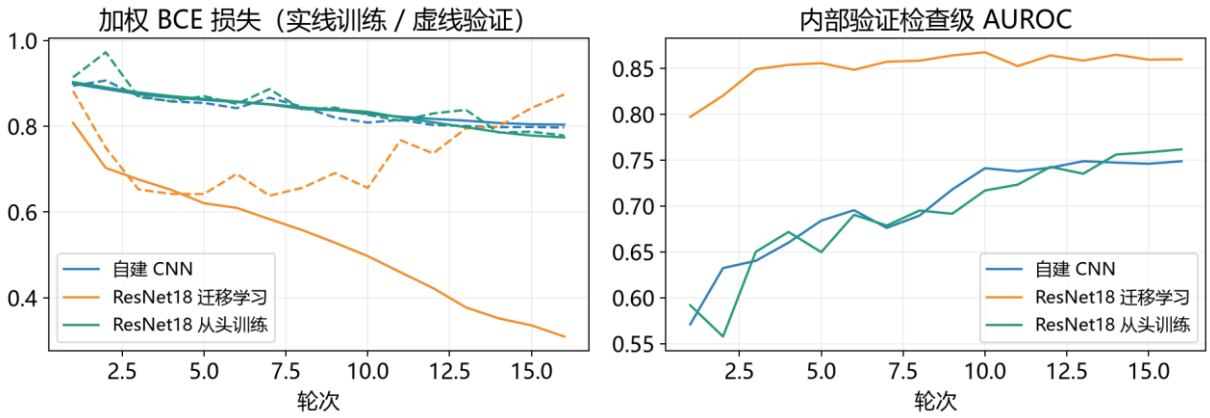


图 5 种子 42 的训练 / 验证损失与内部验证检查级 AUROC。

迁移学习展示运行的最后一轮训练图像 AUROC 为 0.965，内部验证图像 AUROC 为 0.837，反映出训练与开发样本之间的泛化差距。训练又采用在线随机增强，两个指标的输入分布并不完全相同。因此结合完整曲线观察，并按预先确定的验证检查级 AUROC 选取最佳轮次，不强制使用最后一轮。逐轮数据见 history.csv。

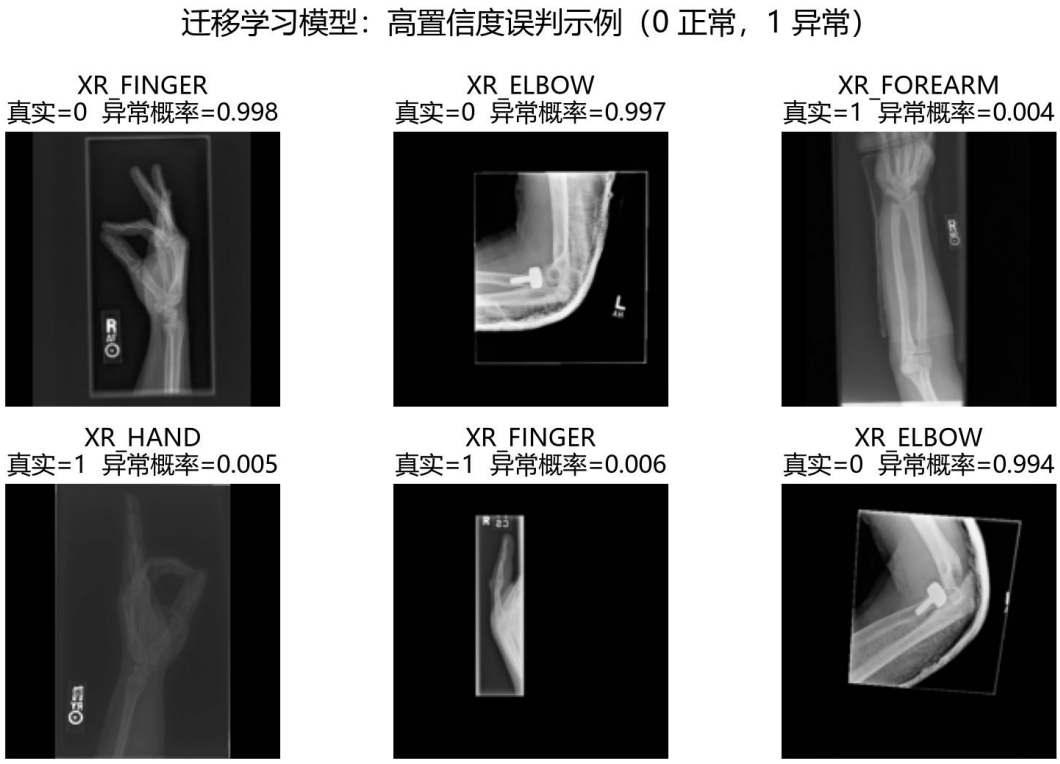


图 6 迁移学习种子 42 中错误置信度最高的六张单图；展示规则事先固定，便于检查失败模式。

所示误判包括含金属固定结构的正常标签影像，以及亮度较低、视野较窄的异常标签影像，提示需要检查模型对器械、亮度及视野变化的稳健性。现有标签没有病灶位置，具体错误成因仍需额外标注验证。训练使用图像级采样，使多视图较多的检查贡献更大权重；某张视图也可能不显示检查标签所对应的异常，这些弱标签因素限制了单图结果的解释。

7 实验四：腮腺 MRI 数据审计

7.1 数据来源与替代原因

课程本地文件仅提供 MURA 分类数据，未发现腮腺 MRI 及掩膜，因此补充使用 Dhafer Honi 发布的公开数据集 parotid gland tumours dataset，版本 1，DOI 10.17632/wrwh5jxptz.1，许可为 CC BY 4.0。[3]下载后计算并固定原始 ZIP 的 SHA256，供后续复现校验；原图、标签和展示图分别位于 IMAGE、LABEL 和 DRAW IMAGE 文件夹。

原始包实际包含 2,110 张原图、2,110 张标签以及 2,110 张标注展示图。网络输入仅使用原始 IMAGE，未将带彩色标注的 DRAW IMAGE 当作输入，避免答案信息泄漏。发布说明中提到的患者信息 Excel 未包含在下载包中，因此下面的病例分组只能依据文件名保守推断。

审计项目	数量 / 处理
原始图像—掩膜对	2110
尺寸不一致，无法确认空间对齐	701
额外灰度编码，语义未确认	94
最终保留	1315
训练 / 内部验证 / 测试	785 / 264 / 266
病例组交叉与相同图像跨集合	均为 0（按本文推断规则）

7.2 标签解释与质量控制

抽查标签与彩色展示图发现：255 的白色区域表示肿瘤，85 或 127 的灰色区域表示腮腺。故肿瘤二值掩膜定义为原标签灰度严格等于 255。若直接把所有非零像素都置为 1，会把正常腮腺一并算入肿瘤，改变任务定义。对存在其他灰度编码的样本，不猜测其类别含义，统一排除。

尺寸不一致可能来自裁剪或导出方式差异；直接把掩膜缩放到原图大小不能证明两者在同一视野中配准。本实验没有使用待学习模型“修正”标签，也未依据测试性能筛选样本，而是在划分前按固定审计条件排除。完整原因在 segmentation_exclusions.csv 中逐条列出。

该处理使保留子集偏向质量较明确的良性肿瘤，形成选择偏差。保留的 4 张恶性肿瘤图像全部位于训练集，测试集中没有恶性肿瘤，因此本报告的测试 Dice 不代表恶性肿瘤分割能力。

8 分割划分、网络与评价方法

8.1 病例组与预处理

三段文件名同时出现“病例.模态.切片”与“模态.病例.切片”两种顺序，取前两数字中的较大值作为病例编号；两段文件名取首数字。编号 1 和 2 合并，同一数字跨类别文件夹合并，以减少可能的同病例泄漏。使用五折分组划分，第一折为测试、第二折为内部验证、其余三折为训练。此规则是保守推断，并无官方患者表验证，不能宣称已经证明真实患者完全独立。

集合	切片	病例组	肿瘤阳性切片	空肿瘤掩膜
训练	785	82	668	117
验证	264	27	226	38
测试	266	28	227	39

图像和掩膜用相同几何方式保持比例填充到 192×192：图像采用双线性插值，掩膜采用最近邻插值。MRI 非零像素按每图 1%—99%分位数截断归一化。训练图像与掩膜同步进行水平翻转和±10°仿射增强；掩膜不采用连续插值。空掩膜切片保留，用于约束假阳性。

8.2 两种自建分割网络

基础编码器—解码器与 U-Net 共享三层编码器及瓶颈，通道 16→32→64→128；每层包含两次 3×3 卷积、BN 和 ReLU，下采样采用最大池化。解码器用转置卷积逐层恢复尺度。基础模型只使用瓶颈信息；U-Net 把同尺度编码特征拼接至解码器，以保留局部空间信息。[4]两模型输出 1×192×192 的肿瘤概率图。

模型	参数量	训练设置
基础编码器—解码器	434,769	40 轮；batch=16；AdamW；lr=0.001
U-Net	483,153	40 轮；batch=16；AdamW；lr=0.001

8.2 两种自建分割网络：结构对照（续）

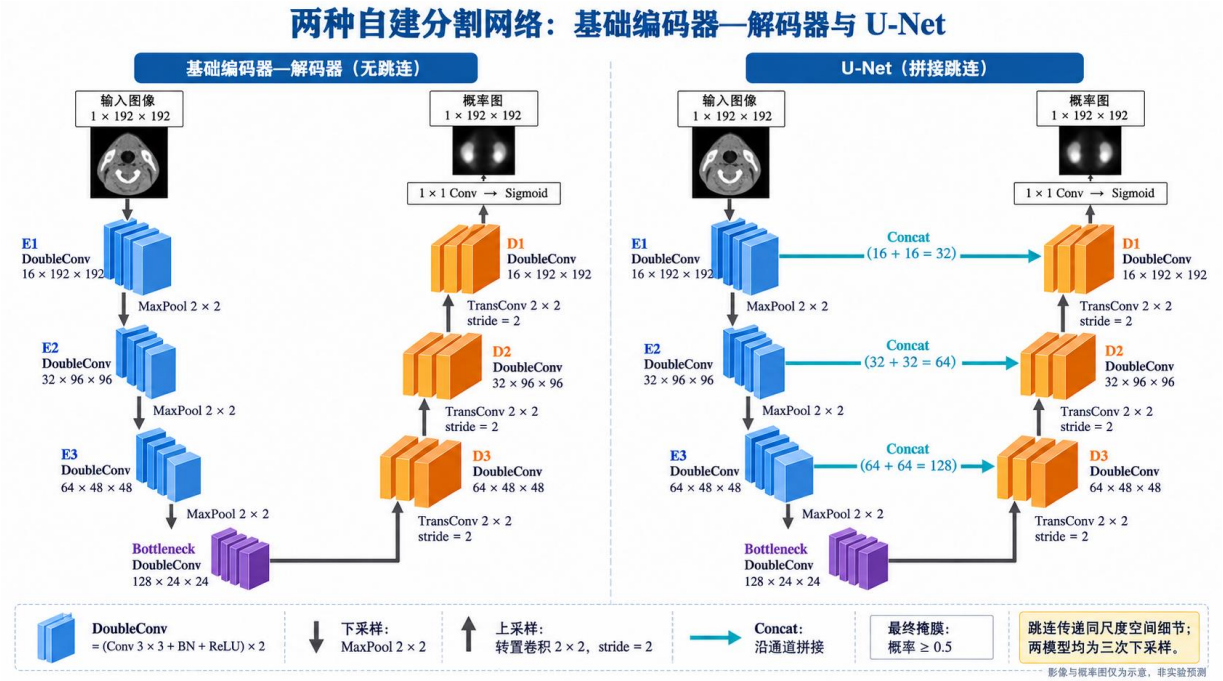


图 7 基础编码器—解码器与 U-Net；青色横向箭头表示沿通道拼接，非逐元素相加。AI 生成结构示意，影像非实验预测。

两网络均执行三次下采样，空间尺寸 192→96→48→24，再经转置卷积恢复至 192。U-Net 在 48、96、192 三个尺度拼接编码特征，拼接后通道分别为 128、64、32，再由 DoubleConv 压缩为 64、32、16。最后的 1×1 卷积输出 logit，推理时经 Sigmoid 得到概率；训练损失直接接收 logit。

8.3 训练目标与选择标准

使用等权重 BCE 与 Soft Dice 损失，分割 BCE 不额外加类别权重；Soft Dice 按单张切片计算后在批内取平均，平滑常数为 1。采用余弦学习率调度与混合精度。各模型按内部验证集肿瘤阳性切片平均 Dice 选择最佳轮次，阈值固定 0.5，不做测试集阈值优化或形态学后处理。

$$L = 0.5\,L_BCE + 0.5\,[1 - (2\Sigma_i p_i g_i + 1)/(\Sigma_i p_i + \Sigma_i g_i + 1)]$$

9 分割结果与 Dice 的解释

$$Dice(P,G) = 2|P \cap G|/(|P| + |G|), \quad IoU(P,G) = |P \cap G|/|P \cup G|$$

Dice 与 IoU 均在 192×192 模型网格上计算。主要报告阳性切片平均 Dice，避免空掩膜抬高指标；同时报告阳性病例组宏平均 Dice，使切片较多的病例不会占更大权重。预测与真值均为空时 Dice 定义为 1，仅一方为空时为 0。所有切片 Dice 与空掩膜正确率作为补充指标。

模型（三种子）	阳性切片 Dice	病例组 Dice	阳性切片 IoU
基础编码器—解码器	0.690 ± 0.009	0.722 ± 0.015	0.578 ± 0.014
U-Net	0.715 ± 0.009	0.750 ± 0.016	0.617 ± 0.012

U-Net 相对基础编码器—解码器的阳性切片平均 Dice 差值为+0.024。比较是在固定子集、输入分辨率和训练预算下进行的；跳连增加了参数量，不能将差异完全归结为某一单独因素。

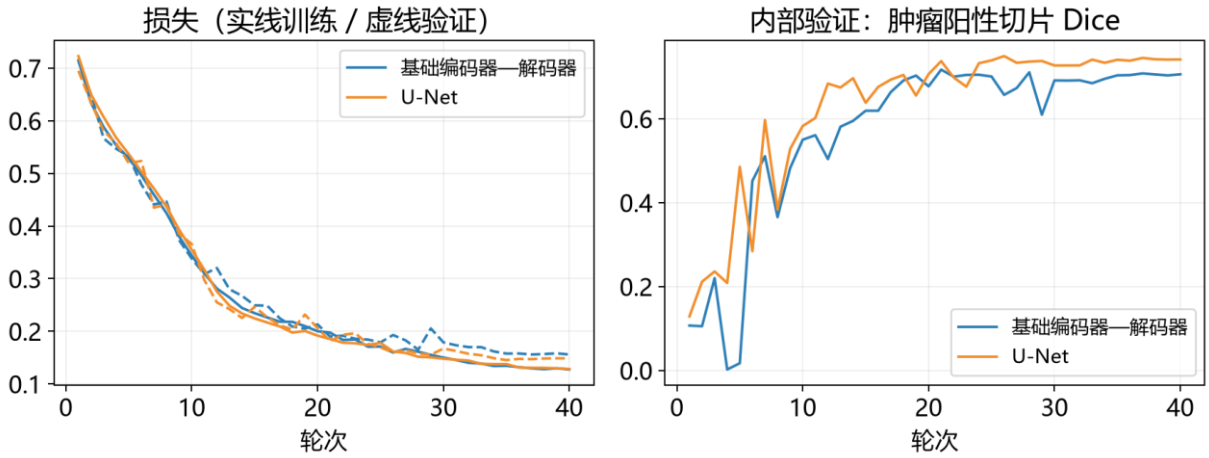


图 8 种子 42 的分割损失与内部验证阳性切片 Dice。

种子 42	全切片 Dice	空掩膜正确率	病例组 Dice 95%区间
基础编码器—解码器	0.681	0.667	[0.638, 0.757]
U-Net	0.709	0.718	[0.666, 0.791]

病例组区间由 1,000 次组级 Bootstrap 得到，仅对当前测试子集的阳性病例组重采样。这里的“组”依据文件名推断，相关区间不能被解释为有官方患者映射支持的多中心置信区间。MRI 缺少一致的像素间距与可靠体积映射，故本实验不报告毫米级 Hausdorff 距离，也不把二维切片 Dice 称为三维体积分割 Dice。

10 分割可视化与失败样本

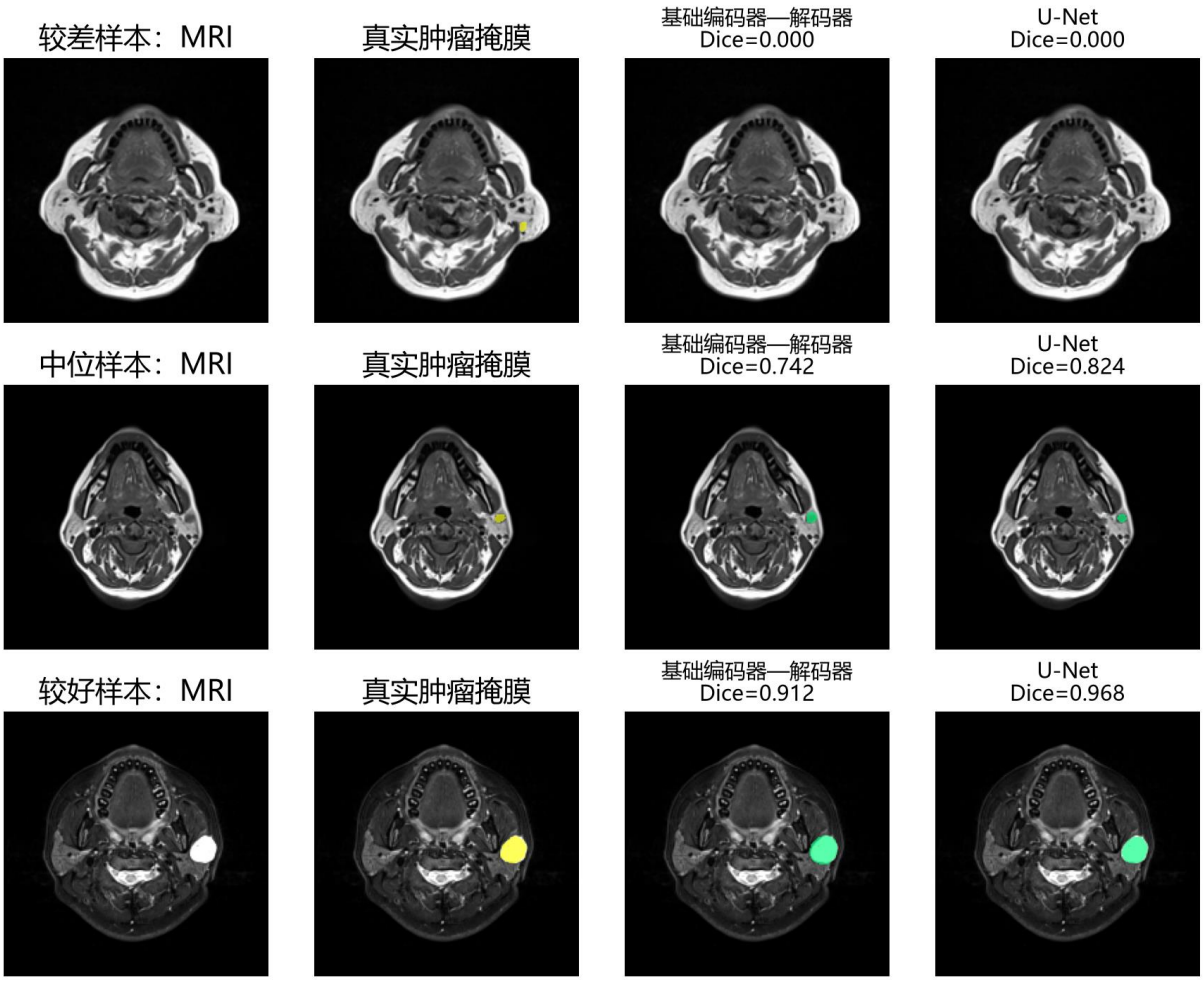


图 9 按种子 42 U-Net 测试 Dice 排序，分别选最差、中位和最好阳性切片；两模型展示同一批输入，叠加色块为真实或预测肿瘤。

示例的选择方式明确保留了较差结果，并非只展示分割成功的图像。Dice 会同时受到边界误差、漏检与额外假阳性区域影响；对像素面积很小的肿瘤，少量像素偏差也可能带来较大的 Dice 变化。因此需要同时观察原图、真实掩膜与预测区域，不能单凭彩色叠加图判断模型可靠性。

U-Net 的跳连可提供较细的局部定位信息，但并不保证每个样本优于基础模型。源数据裁剪差异、分位数归一化、192×192 分辨率及二维训练都可能限制小肿瘤边界表现。后续若获得可靠患者表和统一配准的原始 MRI，可在不接触当前测试集的前提下建立新的训练 / 验证 / 测试划分，比较更高分辨率和三维或多模态网络。

11 程序运行记录、复现与总结



图 10 本地结果查看器实际浏览器截图，指标来自落盘的训练记录；没有手工替换数值。

11.1 运行与交付

项目使用 uv 管理依赖，uv sync --locked 恢复锁定环境。src.prepare 与 src.prepare_segmentation 生成数据清单和审计记录；run_experiments.py 及 run_repeats.py 执行 15 次模型训练；src.analyze 根据真实预测生成图表；src.build_report 生成本报告。src.predict 可加载最佳模型，对新图像输出异常概率或肿瘤掩膜与叠加图。完整命令见 README。

交付内容	文件 / 目录
实验报告	reports/实验三&实验四 自动化 2303 谢怡诺.docx；同名 PDF
代码与依赖	src/、tests/、pyproject.toml、uv.lock
训练与模型	artifacts/classification/、artifacts/segmentation/、artifacts/logs/
划分与审计	data/*manifest.csv、*audit.json、*exclusions.csv
汇总与原始预测	reports/*summary.csv；各运行目录下*predictions.csv
结果查看	reports/viewer.html（本地交互页面）

11.2 完成内容与局限

本实验完成了基础分类网络与不同初始化的残差网络比较，并完成两种自建分割网络的真实训练和 Dice 评价。三个随机种子、病例分组、重复清理和逐样本输出使结果能够被追溯。主要限制包括：MURA 异常标签并非骨折专用标签；MRI 病例身份只由文件名推断；分割子集因质量排除偏向良性病例；输入分辨率与训练预算有限。结果用于课程算法实验，不作为临床使用依据。

参考资料与结果索引

[1] Rajpurkar P, Irvin J, et al. MURA: Large Dataset for Abnormality Detection in Musculoskeletal Radiographs. 2017.

https://arxiv.org/abs/1712.06957

MURA 数据集官方说明（正常 / 异常检查标签、多视图及部位定义）。

https://stanfordmlgroup.github.io/competitions/mura/

[2] He K, Zhang X, Ren S, Sun J. Deep Residual Learning for Image Recognition. CVPR 2016.

https://arxiv.org/abs/1512.03385

[3] Honi D. parotid gland tumours dataset. Version 1. Mendeley Data, 2026. CC BY 4.0.

https://doi.org/10.17632/wrwh5jxptz.1

[4] Ronneberger O, Fischer P, Brox T. U-Net: Convolutional Networks for Biomedical Image Segmentation. 2015.

https://arxiv.org/abs/1505.04597

[5] PyTorch 官方 API：BCEWithLogitsLoss、AdamW、自动混合精度及 torchvision ResNet。

https://docs.pytorch.org/docs/stable/generated/torch.nn.BCEWithLogitsLoss.html

逐次运行结果

分类模型	种子	最佳轮次	检查级 AUC
自建 CNN	42	13	0.7206
自建 CNN	43	14	0.7198
自建 CNN	44	14	0.7205
ResNet18 迁移学习	42	10	0.8721
ResNet18 迁移学习	43	10	0.8645
ResNet18 迁移学习	44	7	0.8500
ResNet18 从头训练	42	16	0.7631
ResNet18 从头训练	43	16	0.7671
ResNet18 从头训练	44	16	0.7527

分割模型	种子	最佳轮次	阳性切片 Dice
基础编码器—解码器	42	21	0.6836
基础编码器—解码器	43	35	0.6861
基础编码器—解码器	44	33	0.7009
U-Net	42	26	0.7069
U-Net	43	27	0.7241
U-Net	44	24	0.7127

报告生成时间：2026-10-25 20:37 CST。所有表格从对应 CSV / JSON 读取，未经手工改写指标。